


Act8_SeriesTiempo_A01284090

Ana Lucía Cárdenas Pérez A01284090

2023-11-14


```
# Creamos serie de tiempo
ventas <- c(4.8, 4.1, 6.0, 6.5, 5.8, 5.2, 6.8, 7.4, 6.0, 5.6, 7.5, 7.8, 6.3,
5.9, 8.0, 8.4)

# Descomposicion de
x = ts(ventas, frequency = 4, start=c(2016,1))
plot.ts(x, col = "red")
```



```
T = decompose(x, type = "m")
plot(T, col = "blue")
```

Decomposition of multiplicative time series



T\$seasonal

```
##           Qtr1      Qtr2      Qtr3      Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179
```

```
ventas_desestacionalizadas = (T$x)/(T$seasonal)
```

```
x3 = 1:16
```

```
y3 = ventas_desestacionalizadas
```

```
N3 = lm(y3~x3)
```

```
N3
```

```
##
```

```
## Call:
```

```
## lm(formula = y3 ~ x3)
```

```
##
```

```
## Coefficients:
```


```
## (Intercept)          x3
```

```
##      5.1080      0.1474
```

```
plot(x3, y3, type = "l")
```

```
abline(N3, col = "red")
```

```
text(6, 7, " ventas = 5.1080 + 0.1474 trimestre")
```



```
f = function(x) {5.1080 + 0.1474*x}
# Los índices estacionales son:
a1 = T$seasonal[1]
a2 = T$seasonal[2]
a3 = T$seasonal[3]
a4 = T$seasonal[4];
f(17)*a1*1000

## [1] 7085.872

f(18)*a2*1000

## [1] 6491.284

f(19)*a3*1000

## [1] 8632.585

f(20)*a4*1000

## [1] 9195.263

# Significancia de B1
summary(N3)

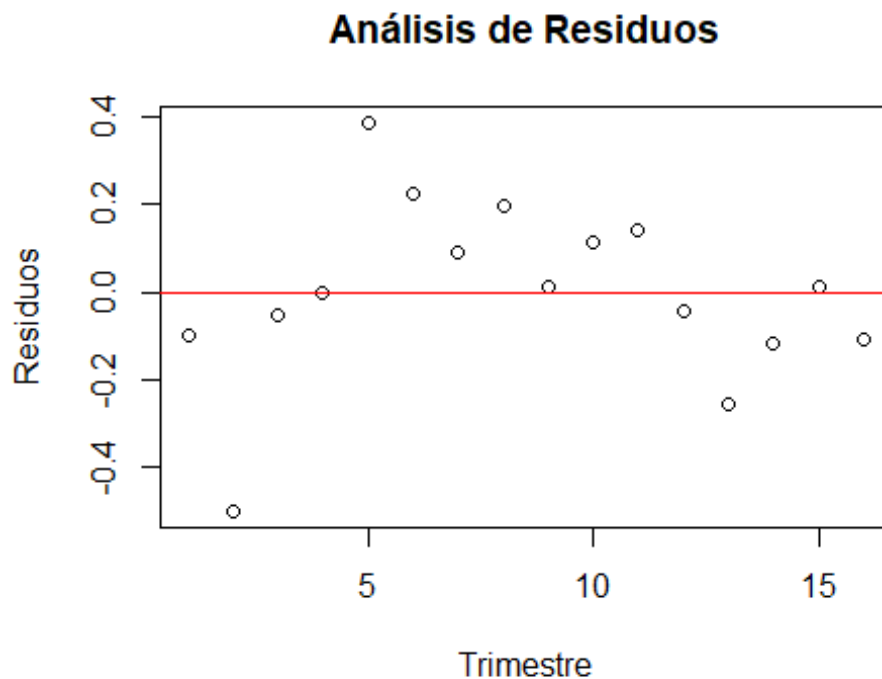
##
## Call:
## lm(formula = y3 ~ x3)
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804     0.11171   45.73  < 2e-16 ***
## x3           0.14738     0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF,  p-value: 4.248e-09

# Variabilidad explicada por el modelo (c.d)
cd = 1 - var(N3$residuals)/var(y3)
cd

## [1] 0.9207911

# Análisis de los residuos
plot(N3$residuals, ylab = "Residuos", xlab = "Trimestre", main = "Análisis de
Residuos")
abline(h = 0, col = "red")
```



```

# Prueba de normalidad
shapiro.test(N3$residuals)

##
##  Shapiro-Wilk normality test
##
## data:  N3$residuals
## W = 0.96379, p-value = 0.7307

# Calcula el CME y el EPAM (promedio de los errores porcentuales) de la
# predicción de la serie de tiempo.
CME = mean(N3$residuals^2, na.rm = TRUE)
CME

## [1] 0.0397064

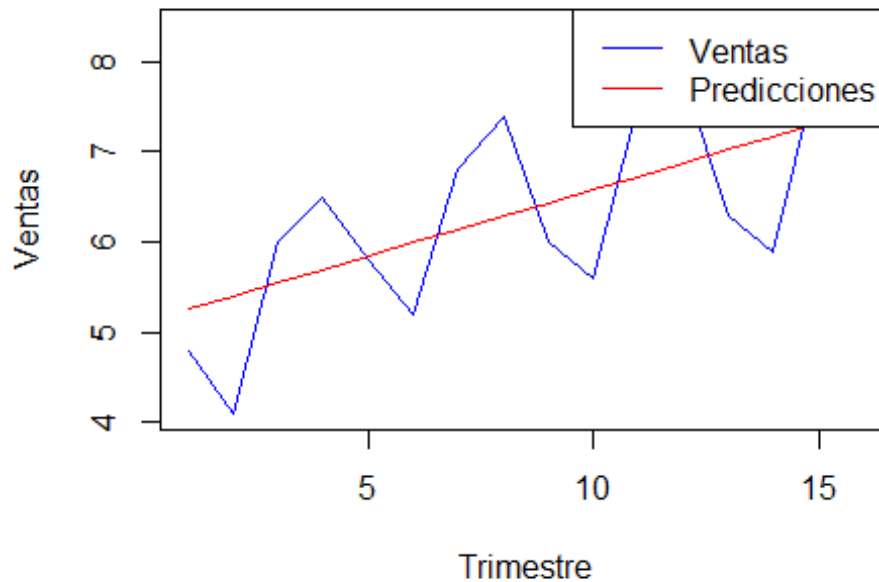
EPAM = mean(abs(N3$residuals/y3 * 100), na.rm = TRUE)
EPAM

## [1] 2.439533

# Dibuja el gráfico de los valores de las ventas y las predicciones vs el
# tiempo
predVentas = predict(N3)
plot(ventas, type = "l", col = "blue", ylab = "Ventas", xlab = "Trimestre",
main = "Ventas vs. Predicciones")
lines(predVentas, col = "red")
legend("topright", legend = c("Ventas", "Predicciones"), col = c("blue",
"red"), lty = 1)

```

Ventas vs. Predicciones



Concluye sobre el modelo: de acuerdo al análisis de verificación de los supuestos, ¿es el mejor modelo que puedes obtener?

Conclusión sobre el modelo lineal

```
cat("Significancia de beta1:\n")
```

```
## Significancia de beta1:
```

```
summary(N3)$coefficients[, "Pr(>|t|)"]
```

```
## (Intercept)          x3
```

```
## 1.209866e-16 4.247717e-09
```

```
cat("\nVariabilidad explicada por el modelo (c.d):\n")
```

```
##
```

```
## Variabilidad explicada por el modelo (c.d):
```

```
cd
```

```
## [1] 0.9207911
```

```
cat("\nAnálisis de los residuos:\n")
```

```
##
```

```
## Análisis de los residuos:
```


```
shapiro.test(N3$residuals)
```

```
##
## Shapiro-Wilk normality test
##
## data: N3$residuals
## W = 0.96379, p-value = 0.7307
```

Trabjando con los valores del test de Shapiro-Wilk, donde un valor p mayor a 0.05 nos indica que no hay mucha evidencia que nos indique que los residuos no sigan una distribución normal. En este caso el valor de p es de 0.7307, el modelo líneal puede ser eadecuado.

```
# Propón un posible mejor modelo para la tendencia de los datos.
# Modelo polinómico de segundo grado
quadraticModel <- lm(y3 ~ poly(x3, 2))

# Gráfica
plot(x3, y3, type = "l", col = "blue", ylab = "Ventas Desestacionalizadas",
xlab = "Trimestre", main = "Modelo Cuadrático de Tendencia")
lines(x3, predict(quadraticModel), col = "red")
```



```
# Realiza el pronóstico para el siguiente año.
# Pronóstico para los siguientes trimestres
pronNextYear = 17:20
pronostico = predict(N3, newdata = data.frame(x3 = pronNextYear))
pronostico
```

```

##          1          2          3          4
## 7.613536 7.760918 7.908300 8.055682

# Realiza el problema de "Un problemilla más" sobre Las ventas trimestraless
de libros de texto universitarios.
# Datos
sales <- data.frame(
  Trimestre = rep(1:4, each = 3),
  A1 = c(1690, 940, 2625, 2500),
  A2 = c(1800, 900, 2900, 2360),
  A3 = c(1850, 1100, 2930, 2615)
)

# Promedios móviles de cuatro trimestres
sales$PromedioMovil4 <- rowMeans(sales[, c("A1", "A2", "A3")])

# Promedios móviles centrados
sales$PromedioMovilCentrado <- (c(NA, head(sales$PromedioMovil4, -1)) +
c(tail(sales$PromedioMovil4, -1), NA)) / 2

# Visualizar resultados
sales

##   Trimestre   A1   A2   A3 PromedioMovil4 PromedioMovilCentrado
## 1          1 1690 1800 1850          1780.000                NA
## 2          1  940  900 1100           980.000          2299.167
## 3          1 2625 2900 2930          2818.333          1735.833
## 4          2 2500 2360 2615          2491.667          2299.167
## 5          2 1690 1800 1850          1780.000          1735.833
## 6          2  940  900 1100           980.000          2299.167
## 7          3 2625 2900 2930          2818.333          1735.833
## 8          3 2500 2360 2615          2491.667          2299.167
## 9          3 1690 1800 1850          1780.000          1735.833
## 10         4  940  900 1100           980.000          2299.167
## 11         4 2625 2900 2930          2818.333          1735.833
## 12         4 2500 2360 2615          2491.667                NA

# Calcular índices estacionales
indices_estacionales <- c(
  mean(sales$A1) / mean(sales$PromedioMovilCentrado[1:3]),
  mean(sales$A2) / mean(sales$PromedioMovilCentrado[4:6]),
  mean(sales$A3) / mean(sales$PromedioMovilCentrado[7:9])
)

# Visualizar resultados
indices_estacionales

## [1]          NA 0.9425076 1.1040433

# Encontrar el trimestre con el mayor índice estacional
trimestre_max_estacional <- which.max(indices_estacionales)

```



```
# Visualizar resultados
trimestre_max_estacional

## [1] 3
```

El resultado anterior, 3, si tiene sentido. Si visualizamos los valores en la tabla del problema, podemos ver que el trimestre 3 siempre obtuvo la mayoría de las ventas, por lo que su promedio e índice es el mayor de la lista.